

Optimisez la gestion & nettoyez les données du stock d'une boutique



Situation actuelle (constats)

- Données réparties entre **ERP** (référentiel & stock) et **site Web** (SKU, ventes).
- **Références non alignées** → jointures incertaines, reporting instable.
- **Qualité hétérogène** : valeurs aberrantes, manquants, statuts incohérents.

Impacts business (risques)

- Pilotage stock : **surstock / ruptures** (et trésorerie immobilisée).
- Pilotage commercial : difficulté à identifier **best-sellers / long tail**.
- Fiabilité CODIR : indicateurs **contestables** → perte de confiance dans la data.

Objectif de la mission (livrable)

- **Consolider** ERP + Web via la **table de liaison** (référentiel unique).
- **Tracer** les anomalies (corriger / exclure / prioriser).
- Produire des KPI : **CA, volumes, stock, corrélations** + recommandations.

Nos données « produit » sont dispersées et partiellement incohérentes → décisions stock/prix/assortiment



DONNÉES SOURCES & PÉRIMÈTRE D'ANALYSE

3

Source	DF origine	Nettoyages (règles appliquées)	DF retraité
ERP	825	– 3 prix < 0 ; – 2 stocks < 0 dont le produit en écart / Final	820
Web (WordPress)	1513	Filtre “produits” : 1513 → 716 (– 797 lignes hors produits) ; puis – 2 produits sans SKU_clean	714
Final (ERP + Web)	-	Jointure via liaison + contrôles d'unicité	713

Qualité clé Web Sur le Web brut (1513)

- SKU_clean manquants : 85
- Doublons SKU_clean : 798 (effet “dump WordPress” : variations/entrées multiples — pas le dataset produit final)
- Après filtre produits (716) : 2 SKU_clean manquants → 714 exploitables ; 0 doublon SKU_clean sur les produits.



Objectif : revenir à “1 produit = 1 clé” avant toute analyse KPI (sinon les ventes/CA sont comptées plusieurs fois).

Pipeline de traitement des données

1_ Profiling & cadrage

Objectif : comprendre les champs, types, manquants, doublons, périmètre.

2_ Règles métier & qualité

=> ERP : cohérence stock / statut ; exclusions $\text{prix} < 0$, $\text{stock} < 0$.
=> Web : filtre “produits”, contrôle SKU.

3_ Normalisation des clés (Feature engineering)

Création sku_clean, standardisation formats, unicité “1 produit = 1 clé”.

4_ Jointures contrôlées & audit des écarts

ERP ↔ liaison (left pour auditer manquants) → ERP+Web (inner pour KPI fiables).

5_ Dataset final + KPI & insights

CA, volumes, stocks, corrélations + recommandations CODIR

- On commence par *qualifier* la donnée, puis on applique des règles métier pour éviter les KPI faux.
- Ensuite on sécurise les clés (sku_clean) parce que la majorité des bugs de reporting viennent des jointures.
- Deux sorties : une pour l’audit (traçabilité) et une pour l’analyse (KPI fiables).

ERP : anomalies métier / valeurs invalides

- **3 prix < 0** → flag + exclusion dataset analysis (conservé en audit)
- **2 stocks < 0** → flag + exclusion dataset analysis (audit)
- **4 incohérences stock_status vs stock_quantity** → correction / standardisation
- **Incohérences stock vs onsale_web :**
 - instock & onsale_web=0 : 65
 - outofstock & onsale_web=1 : 48→ à qualifier métier (tracer et corriger)

WEB : périmètre & clé de jointure

- post_type hétérogène : **716 product / 714 attachment / 83 NaN** → **filtre produits**
- **SKU_clean manquants : 85 / 1513** (mais **2 / 716** sur périmètre produit) → **non joignable, exclu df_web_analysis**
- **SKU non conformes : 2** (ex : 13127-1, bon-cadeau-25-euros) → **conserver en texte, cas métier**
- **Doublons SKU_clean : 798** (dus au mix product/attachment + NA) → **résolu par filtrage périmètre produit**

LIAISON : complétude mapping

- **91 id_web manquants / 825 (≈ 11,03%)** → **pas de reconstruction**, tracer l'impact
- Point rassurant : product_id **unique et complet** ; **0 SKU web orphelin** sur périmètre analysé

Contrôles réalisés (ERP)

Unicité : product_id unique (pas de doublons bloquants).

Cohérence stock : alignement **stock_status** ↔ **stock_quantity** (correction des incohérences).

Valeurs impossibles : exclusion 3 prix < 0 et 2 stocks < 0 du dataset “analysis”.

Traçabilité : anomalies conservées dans le dataset “audit” (justification).

Correction si stock_status → incohérent



Extrait de code Notebook

```
# règle métier : stock_status dérivé du stock_quantity
df_erp["stock_status_2"] = df_erp["stock_quantity"].apply(
    lambda q: "instock" if q > 0 else "outofstock"
)

# correction des incohérences
mask = df_erp["stock_status"] != df_erp["stock_status_2"]
df_erp.loc[mask, "stock_status"] = df_erp.loc[mask, "stock_status_2"]

# exclusions pour dataset analysis
df_erp_analysis = df_erp[(df_erp["price"] >= 0) & (df_erp["stock_quantity"] >= 0)]
```

➡ **Objectif** : éviter les KPI “fantômes” (CA négatif, stock négatif) et fiabiliser la consolidation.

Filtre produits (justification 1513 → 716 → 714)



Objectif : garantir 1 SKU_clean = 1 produit, sinon CA/ventes sont mécaniquement surcomptés.

```
df_web["sku_clean"].duplicated().sum()
```

- 798 doublons = 714 doublons hors NA + 84 doublons NA (85 NA → 84 doublons).
- Après filtre produits : 716 lignes, seulement 2 sans SKU_clean → 714 clean.

```
# 1) Merge contrôlé (audit) : on garde tout L'ERP et on trace les écarts
df_merge_check = df_merge.merge(
    df_web_analysis,
    left_on="id_web",
    right_on="sku_clean",
    how="left",
    indicator=True
)

print(df_merge_check["_merge"].value_counts(dropna=False))
# both 713 | left_only 107 | right_only 0

# 2) Dataset final KPI : uniquement les matchs + métriques web exploitables
df_final_web = (
    df_merge_check.loc[
        (df_merge_check["_merge"] == "both") &
        (~df_merge_check[web_cols].isna().all(axis=1))
    ]
    .drop(columns=["_merge"])
    .copy()
)
```



CONTRÔLES POST-CONSOLIDATION AVANT KPI

Avant de calculer CA / stock / corrélations, on valide que le dataset KPI est cohérent, unique et exploitable.

```
assert df_final_web["product_id"].is_unique
assert df_final_web["sku_clean"].is_unique
assert not (df_final_web[web_cols].isna().all(axis=1)).any()

print("✅ Tests OK : clés uniques et métriques Web présentes.")
```

Test de contrôle	Résultat attendu	Résultat obtenu	Action
Unicité produit (<i>product_id</i> , <i>sku_clean</i>)	0 doublon	0 doublon sur 713	✅ OK
Métriques Web exploitables (<i>web_cols</i>)	pas "tout NA"	filtre appliqué sur both + métriques	✅ OK
Valeurs impossibles (<i>price</i> <0, <i>stock</i> <0)	0	exclus du périmètre analysis	✅ OK
Cohérence stock (<i>stock_status</i> vs <i>stock_quantity</i>)	aligné	corrections en amont	✅ OK
Couverture mapping	écarts documentés	107 left_only (ERP sans Web)	⚠️ À traiter




Objectif : distinguer “premium légitime” vs “erreur de donnée” avant de calculer CA/marges.

Méthodes utilisées

- **Boxplot + IQR** (Q1, Q3, IQR = $Q3 - Q1$) pour repérer les valeurs extrêmes.
- Seuils usuels : $< Q1 - 1,5 \times IQR$ ou $> Q3 + 1,5 \times IQR$.
- Contrôle métier : croiser les outliers avec **ventes**, **catégorie produit**, **libellé**.

Répartition des prix TTC (boxplot) — df_final_web



Interprétation

- Un outlier peut être **normal** (vin premium, millésime rare).
- Un outlier devient suspect si :
 - prix extrême + **ventes incohérentes** (ou nulles)
 - prix extrême + **produit “standard”**
 - **prix négatif** (erreur certaine → exclu en amont)

Décision

Outliers “premium” : **conservés** (segment à piloter)
Outliers “erreur” : **corriger ou exclure** (trace en audit)

Avant le CA, on sécurise le prix : un boxplot/IQR met en évidence les extrêmes. Mais on ne traite pas automatiquement un prix élevé comme une erreur : on le recoupe avec le métier. En revanche, les prix négatifs sont éliminés du dataset d’analyse.

PRIX : ZOOM SUR LES EXTRÊMES (OUTLIERS) & DÉCISION – MÉTHODE IQR



On ne “nettoie” pas un segment premium : on qualifie les extrêmes et on ne retire que l’incohérent.

```
# --- Statistiques descriptives (inclut quartiles) ---
desc = df_price["price"].describe().round(2)
display(desc)
```

```
# --- Calcul IQR ---
q1 = desc["25%"]
q3 = desc["75%"]
iqr = q3 - q1

lower = q1 - 1.5 * iqr
upper = q3 + 1.5 * iqr
```

```
Q1 (25%) : 14.05
Q3 (75%) : 42.00
IQR      : 27.95
Borne basse (Q1 - 1.5*IQR) : -27.87
Borne haute (Q3 + 1.5*IQR) : 83.92
```

```
Nombre d'articles atypiques (IQR) : 31
Proportion d'outliers dans le catalogue : 4.35%
```

```
# --- Nombre + proportion d'outliers (prix atypiques) dans le catalogue ---
mask_iqr_outliers = (df_price["price"] < lower) | (df_price["price"] > upper)
nb_outliers = mask_iqr_outliers.sum()
nb_total = len(df_price)
pct_outliers = nb_outliers / nb_total * 100

print(f"Nombre d'articles atypiques (IQR) : {nb_outliers}")
print(f"Proportion d'outliers dans le catalogue : {pct_outliers:.2f}%")
print("")

# Affichage des outliers
print("Affichage des outliers")
print("-"*30)
display(
    df_price.loc[mask_iqr_outliers, ["product_id", "product_type", "price", "purchase_price", "stock_quantity", "stock_status"]]
    .sort_values("price")
    .head(31)
)
```

	product_id	product_type	price	purchase_price	stock_quantity
213	4359	Champagne	85.6	51.93	112
594	5767	Vin	175.0	90.42	12
226	4402	Cognac	176.0	78.25	11
631	5892	Champagne	191.3	116.06	98
458	5001	Vin	217.5	116.87	18
207	4352	Champagne	225.0	137.81	0

» CA TTC estimé sur le périmètre consolidé (713 produits) pour donner un ordre de grandeur CODIR sur le mois d'octobre.

```
# On travaille sur le périmètre avec données Web disponibles
df_ca = df_final_web.copy()

# CA par article
df_ca["ca_par_article"] = df_ca["price"] * df_ca["total_sales"]

# CA total du site (estimation)
ca_total = df_ca["ca_par_article"].sum()
```

Nombre de produits pris en compte : 713
CA TTC total estimé ($\Sigma \text{ price} * \text{total_sales}$) : 143324.1

	price	total_sales	ca_par_article
0	24.2	6.0	145.2
1	34.3	9.0	308.7
2	20.8	0.0	0.0
3	14.1	12.0	169.2
4	46.0	3.0	138.0

- Le Top 10 sert à repérer les **locomotives** (prix $\times$ volume).
- On surveillera le risque : **rupture** sur ces références = effet direct sur CA.

```
# Top produits contributeurs au CA
top_ca = (
    df_ca[["product_id", "product_type", "post_title", "price", "total_sales", "ca_par_article"]]
    .sort_values("ca_par_article", ascending=False)
    .head(10)
)
```


	product_id	product_type	post_title	price	total_sales	ca_par_article
207	4352	Champagne	Champagne Egly-Ouriat Grand Cru Millésimé 2008	225.0	11.0	2475.0
631	5892	Champagne	Coteaux Champenois Egly-Ouriat Ambonnay Rouge ...	191.3	6.0	1147.8
208	4353	Champagne	Champagne Egly-Ouriat Grand Cru Brut Rosé	79.5	14.0	1113.0
626	5826	Vin	Agnès Levet Côte Rôtie Améthyste 2017	41.2	20.0	824.0
704	6212	Vin	Domaine des Comtes Lafon Volnay 1er Cru Santen...	115.0	7.0	805.0
473	5026	Champagne	Champagne Agrapart & Fils Minéral Extra Br...	86.8	9.0	781.2
464	5008	Vin	Domaine des Comtes Lafon Volnay 1er Cru Santen...	105.0	7.0	735.0
594	5767	Vin	Camille Giroud Clos de Vougeot 2016	175.0	4.0	700.0
693	6126	Champagne	Champagne Gosset Célébris Vintage 2007	135.0	5.0	675.0
472	5025	Champagne	Champagne Agrapart & Fils L'Avizoise Extra...	112.0	6.0	672.0

PARETO CA : LECTURE “LONG TAIL” ET IMPLICATIONS

13



61 % du catalogue représente 80 % du CA TTC → pas de concentration type 80/20.



80% du CA atteint avec 434 produits sur 713 (60.9% du catalogue ; $x \approx 60.9\%$)

CA TTC total estimé : 143,324.10
Nombre d'articles pour atteindre 80% du CA TTC : 434 / 713
Part du catalogue correspondante : 60.9%
CA TTC cumulé atteint par ce groupe : 80.0%

- Contrairement à beaucoup de catalogues où 20% des produits font 80% du CA, ici c'est très diffus.
- Le pilotage doit donc être “catalogue-driven” : qualité des données, disponibilité stock et visibilité du long tail.


VOLUMES VENDUS : TOP PRODUITS EN QUANTITÉS

14

» Les “champions en volume” ne sont pas forcément les “champions en CA” → utile pour piloter l’offre et le stock.

	product_id	post_title	product_type	price	total_sales
0	4867	Château De La Selve IGP Coteaux de l'Ardèche M...	Vin	9.9	36.0
1	4203	Mas Laval IGP Pays d'Hérault Les Pampres Blanc...	Vin	9.9	27.0
2	4275	I Fabbri Chianti Classico Lamole 2017	Vin	14.9	24.0
3	4647	Bernard Baudry Chinon Rouge La Croix Boissée 2017	Vin	28.5	22.0
4	4726	François Baur Pinot Noir Schlittweg 2017	Vin	12.7	22.0
5	6129	Moulin de Gassac IGP Pays d'Hérault Guilhem BL...	Vin	5.2	20.0
6	5826	Agnès Levet Côte Rôtie Améthyste 2017	Vin	41.2	20.0
7	4220	Xavier Frissant Touraine Amboise Chenin Les Pi...	Vin	11.6	18.0
8	5778	Maurel Pays d'Oc Merlot 2018	Vin	5.8	17.0
9	6569	Decelle-Villa Chorey-Lès-Beaune 2016	Vin	29.0	17.0

- Ces produits peuvent être des **produits d'appel** (volume élevé, prix modéré).
- Action stock : sécuriser la disponibilité (risque de **rupture**).



»»» **Objectif : repérer les références où le stock est disproportionné vs les ventes (cash immobilisé) ou insuffisant (rupture).**

Top 10 des produits avec le plus de mois de stocks

	post_title	stock_quantity	total_sales	mois_stock	price
0	Champagne Gosset Grand Millésime 2006	125	4.0	31.25	53.0
1	Champagne Gosset Célébris Vintage 2007	138	5.0	27.60	135.0
2	Champagne Egly-Ouriat Premier Cru Les Vignes d...	81	3.0	27.00	51.6
3	Champagne Egly-Ouriat Grand Cru Brut Tradition	125	5.0	25.00	59.0
4	Champagne Mailly Grand Cru Brut Rosé	71	3.0	23.67	37.5
5	Champagne Larmandier-Bernier Latitude	115	5.0	23.00	39.0
6	Champagne Gosset Grand Rosé	91	4.0	22.75	49.0
7	Champagne Agrapart & Fils L'Avizoise Extra...	136	6.0	22.67	112.0
8	Champagne Egly-Ouriat Grand Cru Extra Brut V.P.	145	7.0	20.71	79.5
9	Champagne Mailly Grand Cru Intemporelle 2010	123	6.0	20.50	59.0

Top 10 des quantités en stocks

	post_title	stock_quantity	stock_status	total_sales
204	Champagne Mailly Grand Cru Les Echansons 2007	145	instock	0.0
206	Champagne Egly-Ouriat Grand Cru Extra Brut V.P.	145	instock	7.0
202	Champagne Gosset Grand Blanc de Blancs	142	instock	7.0
693	Champagne Gosset Célébris Vintage 2007	138	instock	5.0
472	Champagne Agrapart & Fils L'Avizoise Extra...	136	instock	6.0
208	Champagne Egly-Ouriat Grand Cru Brut Rosé	127	instock	14.0
591	Huiles d'Olive Extra Vierge Planeta 3x 10cl	125	instock	10.0
205	Champagne Egly-Ouriat Grand Cru Brut Tradition	125	instock	5.0
73	Champagne Gosset Grand Millésime 2006	125	instock	4.0
72	Champagne Gosset Grande Réserve	123	instock	8.0

```
# => mois_de_stock = stock_quantity / total_sales
df_stock["mois_stock"] = (df_stock["stock_quantity"] / df_stock["total_sales"]).round(2)
```


```
# Nb de références avec stock > 0
nb_refs_stock_pos = (df_stock["stock_quantity"] > 0).sum()
```

- **Mois de stock élevé + ventes faibles** ⇒ immobilisation (à déstocker / promo / déréférencer).
- **Ventes élevées + stock faible** ⇒ risque de rupture (réassort prioritaire).
- **Segment premium** : stock parfois volontairement faible/élevé → arbitrage métier.

2) Taux de marge unitaire en % (ex: 25.23)

```
df_margin["taux_marge_pct"] = np.where(
    df_margin["purchase_price"] > 0,
    ((df_margin["prix_ht"] - df_margin["purchase_price"]) / df_margin["purchase_price"]) * 100,
    np.nan
)
```

Taux de marge moyen par type de produit




- **Forte hétérogénéité** des marges selon les familles de produits.
- Identification de **valeurs aberrantes** (marges excessives ou négatives) à **auditer** : erreur de prix d'achat, mauvais rattachement produit, ou cas métier (promos, références spécifiques).

	post_title	price	prix_ht	purchase_price	taux_marge_pct
	Cognac Frapin VSOP	62.50	52.08	27.21	91.41 %
	Wemyss Malts Single Cask Scotch Whisky Chocolate Moka Cake 2005 Strathclyde	93.00	77.50	40.49	91.41 %
	Cognac Frapin Château de Fontpinot 1989 20 Ans d'Age	157.00	130.83	69.08	89.39 %
	Kingsbarns Distillery Lowland Single Malt Whisky	57.00	47.50	25.08	89.39 %
	Wemyss Malts Single Cask Scotch Whisky Choc 'n' Nut Pretzel 2001 Bunnahabhain	122.00	101.67	54.24	87.44 %


	post_title	price	prix_ht	purchase_price	taux_marge_pct
	Champagne Egly-Ouriat Grand Cru Blanc de Noirs	12.65	10.54	77.48	-86.39 %
	Huile d'Olive Extra Vierge Planeta 50cl	13.10	10.92	8.43	29.50 %
	Champagne Gosset Grande Réserve	39.00	32.50	24.86	30.73 %
	Huiles d'Olive Extra Vierge Planeta 3x 10cl	19.50	16.25	12.07	34.63 %
	Champagne Agrapart & Fils Terroirs Brut Blanc de Blancs Grand Cru	62.10	51.75	38.04	36.04 %

» On quantifie les relations clés : élasticité prix, alignement stock-demande, spécificité du premium.

```
corr = df_corr.corr(method="spearman").round(2)
```



```
corr = df_corr.corr(method="pearson").round(2)
```



Résultats :

- **Prix ↔ ventes** : corrélation **négative** (Pearson $\approx -0,52$; Spearman $\approx -0,70$) → élasticité prix.
- **Ventes ↔ stock** : corrélation **positive** (Pearson $\approx +0,44$; Spearman $\approx +0,76$) → stock globalement **aligné sur la demande**.
- **Prix ↔ stock** : relation plus **faible/non linéaire** (Pearson $\approx -0,11$; Spearman $\approx -0,57$) → gestion différente des références premium.

Interprétation :

- La demande baisse quand le prix augmente (logique attendue) → utile pour **stratégie promo/assortiment**.
- Les produits qui vendent ont tendance à être mieux stockés → pilotage possible via **seuils de réassort**.

Axe 1 — Pilotage prix / promo (élasticité)

- Prix ↔ ventes : corrélation négative (élasticité)

=> Actions :

- Tester une stratégie **promo ciblée** sur produits sensibles au prix
- Distinguer **premium** (moins promo) vs **standard** (promo possible)

Axe 2 — Stock / réassort / déstockage (couverture)

- Surstocks (mois de stock élevé) vs tensions (ventes fortes + stock faible)

=> Actions :

- Mettre en place des seuils : **réassort prioritaire / déstockage**
- Suivre la couverture sur plusieurs mois (saisonnalité)

Axe 3 — Gouvernance data (clé de jointure)

- Web brut bruité ; liaison incomplète ; 107 produits ERP sans métriques Web

=> Actions :

- Process de **maintenance de la table de liaison** (ownership, MAJ, contrôles)
- Contrôles automatisés à chaque extraction (SKU, doublons, manquants)



Prochaine étape : industrialiser un refresh mensuel + dashboard (Produit / Ventes / Stock).

»» Les KPI sont fiables sur le périmètre consolidé, mais certaines hypothèses limitent l'interprétation "finance".

4 sujets de préoccupation

- **price supposé TTC** (TVA non isolée)
→ CA présenté = **CA e-commerce estimé**, pas CA comptable.
- **Pas de promos / remises / retours** dans les données
→ CA potentiellement **surestimé**, et élasticité prix à interpréter avec prudence.
- **Fenêtre d'observation : 1 mois (octobre)**
→ effets **saisonnalité** non captés ; stock "mois de couverture" à confirmer sur plusieurs mois.
- **Périmètre KPI = produits matchés ERP ↔ Web (713)**
→ les produits **ERP sans Web** (107 left_only) ne sont pas inclus dans les KPI ventes/CA.

Préconisations

- Enrichir le modèle : **stocks initiaux**, TVA, promos, retours → marge & CA net.
- Mettre en place un suivi **multi-mois** pour robustifier rotation et saisonnalité.



L'analyse est solide sur la qualité et la consolidation. Les limites viennent surtout des variables manquantes pour une lecture financière complète. La suite logique est l'enrichissement du modèle et l'historisation

Responsabilités

- Nommer un **owner** de la table de liaison (métier/ops)
- Définir qui valide : **création SKU**, mapping, correction anomalies

Process (règles & contrôles)

- Standard SKU : format, unicité, gestion variations
- Contrôles qualité systématiques :
 - $\text{prix} < 0$, $\text{stock} < 0$
 - incohérence `stock_status/stock_quantity`
 - `SKU_clean` manquants / doublons
 - `_merge` (both/left_only) suivi dans le temps
- Journal “audit” : anomalies + décision (**corriger** / **exclude** / **conserver**)

Tech (pipeline)

- Pipeline ETL simple : Extract → Clean → Merge → Assurance qualité (unicité, complétude, jointures) → Export
- Exports : `datasets.csv` et/ou `datasets.xlsx`

Compétences Data Analyst

- **Data cleaning & feature engineering** (règles métier, `sku_clean`, IQR)
- **Data merging & audit** (jointures contrôlées, indicator, traçabilité)
- **Analyse & storytelling** (KPI, corrélations Pearson/Spearman, recommandations)