
Les Plus Beaux Logis de Paris

Projet 8 : Analysez l'évolution des prix de l'immobilier avec Python

Analyse du marché, valorisation du portefeuille et classification automatique



Les Plus Beaux Logis de Paris

- *Marché immobilier parisien*
- *Valorisation du portefeuille 2022*
- *Sklearn vs PyCaret*
- *Classification des opportunités*

Nous traiterons successivement les quatre questions business posées par la mission : comprendre le marché, valoriser le portefeuille, comparer les approches de modélisation, puis accélérer la qualification des opportunités.

- **1. Contexte et objectif** Comprendre le marché parisien, valoriser le portefeuille existant et automatiser la qualification des opportunités.
- **2. Analyse exploratoire** Nettoyage, contrôle qualité, tendances 2017-2021, différences par arrondissement et par type de bien.
- **3. Prédiction de valorisation** Baseline sklearn, benchmark PyCaret, comparaison des valorisations et contrôles de cohérence métier.
- **4. Classification automatique** Segmentation K-Means des nouvelles opportunités à partir du prix au m².
- **5. Recommandations** Lecture business, limites, précautions et prochaines étapes.

I. Données et contrôles qualité

26 180

transactions après
"dédoublonnage"

20

arrondissements

2

types de biens

0%

valeurs manquantes

Jeux de données utilisés

- Historique des transactions 2017–2021 sur Paris.
- Portefeuille d'actifs de l'entreprise à valoriser.
- Échantillon de nouvelles opportunités à classer.

Contrôles réalisés


- Détection des doublons exacts et suppression des enregistrements en double.
- Vérification des surfaces > 0 et cohérentes pour le calcul du prix au m^2 .
- Contrôle des variables catégorielles : code postal, type de bien, nom de commune.
- Préservation de la surface réelle comme référence métier pour toutes les valorisations.

Point de vigilance

Les données ne décrivent pas la qualité intrinsèque des biens : état, étage, prestations, DPE, micro-localisation.

II. Évolution du marché parisien (2017–2021)

05



Constats clés

- +10% environ sur le prix moyen des appartements entre 2017 et 2021.
- Hausse continue jusqu'en 2020 puis léger reflux en 2021.
- Volume annuel encore important malgré le repli 2020–2021.

Repères


2017 : 9 492 €/m²
2020 : 10 675 €/m²
2021 : 10 456 €/m²

Lecture : tendance de fond haussière, mais sensibilité à la conjoncture sur les dernières années.

III. Une forte segmentation géographique

Écarts de prix au m² entre arrondissements

- Les 20 arrondissements suivent la **même tendance macro**, mais à des **niveaux très différents**.
- Les arrondissements centraux restent durablement au-dessus des périphéries.
- Le code postal joue donc un rôle explicatif majeur dans les modèles de valorisation.



Implications métier

- Un même niveau de surface ne porte pas la même valeur selon l'arrondissement.
- La hiérarchie des prix observée renforce la nécessité d'un encodage du code postal.
- Les modèles doivent aussi intégrer le type de bien : local et appartement ne suivent pas le même niveau de prix.
- Pour l'échantillon de classification (75019), la variable géographique n'est plus discriminante : le prix au m² devient alors central.

Top 4

75006 · 75001
75007 · 75004

Bas de fourchette

75019 · 75020
75013 · 75012

IV. Démarche de modélisation retenue

07

Pipeline de prédiction de la valeur foncière

1. Features

Surface réelle
Temps (t_jours)
Code postal
Type de bien

2. Encodage

One-hot encoding
colonnes catégorielles
24 variables finales

3. Modèles

Baseline sklearn
Benchmark PyCaret
Choix sur MAPE

4. Contrôle

Contrôle métier des prix
au m² prédits via
bornes IQR historiques

Choix de la surface réelle

Le client a demandé de raisonner en surface réelle plutôt qu'en surface Carrez. Cette décision a été appliquée à la préparation des features et à la valorisation du portefeuille.

Point méthodologique : la comparaison sklearn vs PyCaret est instructive, mais les protocoles de découpage ne sont pas parfaitement identiques. La comparaison reste donc principalement business, pas académique.

V. Baseline sklearn : un point de départ solide

9,05 %

MAPE test

32 822 €

MAE test

Lecture

- Objectif OC atteint : erreur moyenne < 10%.
- Modèle simple, rapide à expliquer et facile à redéployer.
- Bonne baseline mais relation strictement linéaire.

Limites du modèle linéaire

- Les coefficients supposent des effets additifs et constants.
- Le marché immobilier comporte des non-linéarités et des interactions : surface × arrondissement × type.
- Absence de variables fines : étage, état, prestations, DPE, micro-localisation.
- Le modèle tend à produire plus de cas atypiques sur le contrôle €/m².

Message clé : baseline valide pour un premier cadrage, mais pas optimale pour une mise en production.

VI. PyCaret : benchmark, sélection et optimisation

09

Top modèles benchmarkés sur la MAPE

LightGBM MAPE 3,06 % MAE 25 425 €

ExtraTrees MAPE 3,07 % MAE 18 363 €

RandomForest MAPE 3,22 % MAE 21 255 €

DecisionTree MAPE 3,72 % MAE 24 694 €

Champion retenu : LightGBM

Pourquoi un gain de performance ?

- PyCaret teste plusieurs familles de modèles sur une même base de comparaison.
- Il retient ensuite un seul modèle final : le meilleur sur la métrique cible (ici la MAPE).
- La phase `tune_model()` optimise ensuite ses hyperparamètres.
- Le résultat final est plus performant, mais moins interprétable qu'une simple régression linéaire.

Important : PyCaret ne fait pas une moyenne des modèles sauf si l'on active explicitement du blending ou du stacking.

VII. Valorisation du portefeuille — Scénario sklearn

10

71,23 M€

Particuliers

97,73 M€

Corporate

168,96 M€

Valorisation totale estimée

Lecture métier

- Le segment corporate ressort déjà comme la branche la plus valorisée.
- La régression linéaire tend néanmoins à sur-valoriser certains biens au regard des historiques €/m².
- Ce premier niveau de valorisation reste utile comme point de comparaison.

Niveau de confiance

- MAPE globalement acceptable, mais cohérence métier perfectible.
- Forte part de prédictions hors plage IQR sur les prix au m² implicites.
- Les biens atypiques nécessitent une revue manuelle avant décision d'investissement.

Le portefeuille reste dominé par les locaux commerciaux/assimilés dans ce scénario.

VIII. Valorisation du portefeuille — Scénario PyCaret

11

65,71 M€

Particuliers

87,60 M€

Corporate

153,31 M€

Valorisation totale estimée

Écart vs sklearn

- Particuliers : -5,52 M€ (-7,7%).
- Corporate : -10,13 M€ (-10,4%).
- Total : -15,65 M€ (-9,3%).


Interprétation

- Les deux approches convergent sur le diagnostic business : corporate > particuliers.
- PyCaret produit des valorisations plus prudentes, et plus cohérentes avec les gammes historiques €/m².
- Le modèle gagne en performance, mais son interprétation directe est plus délicate.

Le gain n'est pas seulement statistique : il se traduit par une baisse des cas "hors gabarit" côté métier.

IX. Comparaison des valorisations par segment

12




Ce que montre ce graphique

- Le corporate domine dans les deux approches.
- PyCaret réduit toutes les valorisations, sans inverser la hiérarchie des segments.
- La différence de niveau appelle une restitution prudente : il faut présenter une estimation, pas une vérité de marché.

Lecture recommandée pour Louise :
ordre de grandeur + ordre relatif des
segments

X. Contrôle de cohérence métier : les prix au m²

13



39,93 %

hors IQR
sklearn

23,08 %

hors IQR
PyCaret

Interprétation

- PyCaret réduit les cas atypiques de 16,85 points.
- Soit environ -42% de prédictions hors plage IQR.
- Le résultat renforce la crédibilité business du modèle final.

XI. Recommandations et limites sur la valorisation

14

Ce que je recommande de retenir

- Retenir PyCaret comme meilleur moteur de valorisation pour la suite.
- Conserver la régression linéaire comme baseline explicative et outil de pédagogie.
- Toujours compléter les valorisations par un contrôle métier des prix au m².

Pourquoi ?

Moins de cas hors-plage • mêmes conclusions de segment • estimations plus prudentes

Limites à rappeler au commanditaire

- Les modèles ne connaissent pas l'état des biens, l'étage, les travaux, ni la vacance potentielle.
- L'historique s'arrête à 2021 : la projection 2022 reste sensible à tout changement de marché.
- Les estimations doivent être lues comme des ordres de grandeur, pas comme une valeur notariale.

Les Plus Beaux Logis de Paris

Partie 2

Classification automatique des opportunités d'achat

XII. Nouveau besoin métier : classer plus vite les opportunités

16

Demande de Louise

- Les équipes reçoivent des opportunités d'achat incomplètement décrites.
- Au-delà de l'adresse, de la surface et du prix potentiel, le type de bien n'est pas connu.
- L'enquête manuelle par téléphone est coûteuse en temps et ralentit la prise de décision.

Objectif : pré-qualifier automatiquement en "Appartement" ou "Local commercial/assimilé".

40

opportunités test

75019

même CP

2

classes

Pourquoi K-Means ?

- Pas de labels fournis sur l'échantillon à classer.
- Un seul facteur semble vraiment discriminant : le prix au m².
- K-Means permet de regrouper automatiquement les biens en deux groupes homogènes.

XIII. Préparation des données de classification

17

Variables présentes dans l'échantillon

- valeur_fonciere
- code_postal
- nom_commune
- surface_reelle

Transformation clé

- Calcul du prix au m² = valeur foncière / surface réelle.
- Suppression de la valeur foncière et de la surface, devenues redondantes.
- Pas de variable temps : toutes les données relèvent du même contexte.

Pourquoi ne pas normaliser ?

- Le clustering repose ici sur une seule variable : prix_m2.
- La normalisation ne changerait donc pas la partition, uniquement l'échelle.
- La simplicité renforce la lisibilité de l'approche pour un interlocuteur non technique.

Conclusion : K-Means travaille en 1D sur prix_m2 uniquement.

XIV. K-Means : logique de l'algorithme

18

K-Means cherche 2 centroïdes qui minimisent la distance entre chaque bien et le centre du groupe auquel il appartient.

1. Initialiser

Choisir 2 centres de départ

2. Affecter

Attribuer chaque bien au centre le plus proche

3. Recalculer

Mettre à jour la position de chaque centroïde



4. Stabiliser

Répéter jusqu'à stabilisation

Dans notre cas, la lecture métier est simple : prix/m² bas ≈ appartements ; prix/m² hauts ≈ locaux commerciaux/assimilés.

XV. Résultat du clustering : deux groupes nettement séparés

19



Chiffres à retenir

20 / 20

biens par cluster

7 409

centroïde bas

9 807

centroïde haut

Lecture

La séparation visuelle est nette et le recouvrement faible. Le cluster “bas” est interprété comme “Appartement” et le cluster “haut” comme “Local commercial/assimilé”.

XVI. Synthèse finale et prochaines étapes

20

Ce que le projet permet déjà

- Comprendre les grands déterminants du marché parisien.
- Valoriser rapidement un portefeuille selon plusieurs approches.
- Disposer d'un premier outil de pré-qualification automatique des opportunités.

Message business : agir plus vite, avec des garde-fous métier explicites.

Suite recommandée

- Enrichir les données : état, étage, prestations, DPE, vacance, rendement.
- Comparer les modèles sur un protocole strictement identique pour un benchmark plus académique.
- Valider le clustering sur un petit échantillon labellisé métier avant industrialisation.
- Transformer ces briques en outil de scoring prioritaire pour les équipes acquisition.