

Rapport d'analyse

Projet 9 – Bottleneck

Solutions et préconisations d'utilisation de la base de données pour la data visualisation

Auteur : Henrique Da Costa

Livrable 1 – Rapport documenté

Date : 1 avril 2026

Objet du rapport. Comparer les solutions d'extraction, de traitement et de visualisation des données Bottleneck, puis recommander l'architecture la plus adaptée au besoin métier, au calendrier projet et au livrable final attendu sous Power BI.

1. Introduction

1.1 Objectif du rapport

Le présent rapport a pour objet d'évaluer les différentes solutions envisageables pour mettre la base de données Bottleneck à disposition dans un outil de data visualisation, puis de préconiser l'option la plus pertinente au regard du besoin fonctionnel, de la qualité des données disponibles, du délai de réalisation et des exigences de maintenance.

1.2 Contexte de l'analyse

Bottleneck souhaite accélérer l'usage opérationnel de ses données afin de mieux piloter son activité commerciale. La note de cadrage précise que l'entreprise est en retard sur l'exploitation de la donnée, ce qui pénalise à la fois sa compétitivité, le suivi de ses stocks et sa capacité à identifier de nouveaux relais de croissance, notamment sur le segment sans alcool.

La mission confiée consiste à produire, d'une part, un rapport documenté sur les solutions d'utilisation de la base de données et, d'autre part, un tableau de bord Power BI (.pbix) intégrant au moins trois KPI ainsi que des recommandations business. Le tableau de bord devra être utile au responsable des ventes, à la direction et aux chefs de produits, avec des pages thématiques, des filtres et une lecture suffisamment claire pour un usage quotidien.

Les données fournies couvrent la période du 1er octobre 2022 au 30 septembre 2023. Elles sont livrées sous la forme d'un export SQLite accompagné d'un schéma relationnel, d'un dictionnaire de données et d'une note de cadrage métier.

2. État des lieux et évaluation de la pertinence

2.1 Description de la situation actuelle

La base fournie par Bottleneck est structurée autour de quatre tables : Web, Finance, Sales et Promo. Le dictionnaire de données décrit les rôles respectifs de ces tables : Web porte les attributs descriptifs des produits, Finance les données mensuelles de prix et de présence web, Sales les ventes, commandes et stocks mensuels, et Promo les informations liées aux opérations promotionnelles.

Le schéma relationnel communiqué par OpenClassrooms fait apparaître Finance comme table pivot du modèle, reliée à Web par le SKU et enrichie par Sales et Promo via une clé commune de type période + référence produit. À l'inverse, la copie d'écran du diagramme ER issue de DBeaver montre que les relations ne sont pas physiquement matérialisées dans l'export SQLite. Il a donc fallu reconstituer la logique relationnelle attendue à partir des clés et vérifier sa cohérence par audit SQL.

Les contrôles réalisés montrent que les clés sont uniques dans chacune des tables, que les tables Sales et Promo s'alignent intégralement sur Finance, et que le grain métier est homogène au niveau produit × mois. Ces éléments confirment que la base peut être exploitée dans un modèle analytique stable.

Cartographie synthétique des tables

Table	Grain principal	Champs clés	Rôle analytique
Web	1 ligne = 1 SKU	SKU, Product_type, Segment, Post_title	Dimension produit
Finance	1 ligne = 1 produit × 1 mois	Key_Finance, Date, SKU, Price, Purchase_Price	Table pivot / socle factuel
Sales	1 ligne = 1 produit × 1 mois	Key_Sales, Sales, Orders, Stock	Mesures commerciales et stock
Promo	1 ligne = 1 produit × 1 mois	Key_Promo, Start_Date, End_Date, Sales_Offer, Price_Offer	Mesures promotionnelles

2.2 Évaluation de la pertinence des données existantes

Les données disponibles sont pertinentes pour construire un tableau de bord de pilotage commercial. Elles permettent en effet de suivre les principaux leviers évoqués dans la note de cadrage : évolution des prix d'achat, contrôle de la marge, suivi des ventes, analyse des promotions, suivi des stocks et lecture des performances par segment ou portefeuille produit.

L'audit SQL a mis en évidence un point important : 110 SKU sont présents dans Finance mais absents du référentiel Web. Toutefois, ces références ne portent ni ventes ni promotions. Elles sont donc sans impact business direct pour le tableau de bord attendu et peuvent être traitées comme un sous-périmètre technique hors catalogue actif.

En pratique, les données sont suffisamment fiables pour permettre la construction d'une table de faits consolidée. Le principal enjeu n'est donc plus le nettoyage de la donnée, mais son exploitation structurée dans un outil de visualisation.

2.3 Identification des principaux problèmes ou enjeux

- absence de relations physiques visibles dans l'export SQLite, alors que le schéma logique existe bien ;
- représentation hétérogène de la période dans les clés (ex. 2023-1) et dans le champ Date (ex. 2023-01-01), ce qui impose une normalisation lors des traitements ;
- présence, dans la table Web, de nombreux champs techniques issus de WordPress qui sont peu utiles pour l'analyse métier et doivent être écartés du modèle final ;
- besoin d'un tableau de bord lisible, fiable et maintenable dans un calendrier court de quatre semaines ;
- attente métier forte sur la marge, l'inflation fournisseurs, les stocks, la performance promotionnelle et le nouveau segment sans alcool.

3. Besoin d'outils

3.1 Identification des outils nécessaires pour collecter les données

La donnée de départ étant déjà centralisée dans une base SQLite, le besoin de collecte est limité. Il ne s'agit pas de multiplier les sources, mais d'organiser un accès fiable à la source unique fournie par l'entreprise.

Dans ce contexte, un accès direct à la base SQLite via un connecteur compatible (ODBC/SQLite) constitue la solution la plus naturelle pour l'extraction initiale. Une extraction CSV peut également être produite à titre de secours ou pour des contrôles ponctuels, mais elle n'est pas la solution cible.

3.2 Identification des outils nécessaires pour traiter les données

Le traitement doit permettre de normaliser les clés, sélectionner les colonnes utiles, consolider les tables et formaliser le modèle analytique cible. Pour cela, deux niveaux d'outils sont nécessaires : un outil d'audit SQL pour contrôler la cohérence de la base et un outil de préparation des données pour la transformation opérationnelle.

DBeaver est adapté à la phase d'audit et de contrôle. En revanche, pour la phase de préparation intégrée au livrable, Power Query apparaît comme l'outil le plus cohérent : il permet de réaliser des jointures, des filtres, des typages et des transformations documentées directement dans le flux Power BI.

3.3 Identification des outils nécessaires pour analyser les données

L'outil de visualisation doit répondre explicitement au format de livrable demandé (.pbix) et permettre la modélisation, le calcul de KPI, l'interactivité par filtres et la création de pages thématiques. Power BI s'impose donc comme l'outil cible.

Il devra être complété par un modèle de données simple, robuste et orienté métier : une table de faits consolidée au grain produit × mois, une dimension produit issue de Web et une dimension calendrier.

4. Solutions d'extraction, de traitement et de visualisation

4.1 Solutions proposées pour l'extraction des données

Trois options d'extraction sont envisageables dans le contexte du projet :

- **Option A – Connexion directe à la base SQLite** : Connexion de Power BI à l'export SQLite via un connecteur approprié, avec import des tables sources dans Power Query.
- **Option B – Extraction en fichiers CSV** : Export préalable des tables en CSV, puis import des fichiers plats dans Power BI.
- **Option C – Flux ETL intermédiaire** : Passage par un outil de type Power Query centralisé, KNIME ou autre flux ETL pour alimenter un jeu de données préparé avant visualisation.

4.2 Solutions proposées pour le traitement des données

Le traitement peut être assuré selon trois niveaux de sophistication croissante :

- **Traitement léger dans Power Query** : Jointures, typages, filtres, création d'une table de faits consolidée et d'une dimension produit directement dans le fichier Power BI.
- **Traitement via exports CSV et transformations locales** : Préparation externe des données puis réimport des fichiers, avec une maintenance plus manuelle.
- **Traitement industrialisé via ETL dédié** : Construction d'un pipeline plus structuré, potentiellement plus robuste à long terme mais plus coûteux à concevoir pour ce projet.

4.3 Solutions proposées pour la visualisation des données

Le livrable attendu impose Power BI. La réflexion ne porte donc pas sur le choix d'un outil de restitution concurrent, mais sur la bonne manière d'alimenter Power BI pour obtenir un tableau de bord fiable et maintenable.

Le tableau de bord devra être structuré en pages thématiques, avec une page de synthèse exécutive, un suivi de la marge et des prix d'achat, une lecture des ventes et du stock, une analyse des promotions et un focus sur les segments de marché.

Comparatif synthétique des approches

Critère	Connexion directe SQLite	CSV	ETL dédié	Appréciation	Retenue
Fiabilité de la source	Élevée	Moyenne	Élevée	La base unique évite les divergences de version.	Oui
Rapidité de mise en œuvre	Élevée	Élevée	Faible à moyenne	Le délai projet favorise une solution simple.	Oui
Traçabilité des traitements	Élevée via Power Query	Moyenne	Élevée	Power Query documente suffisamment les étapes.	Oui
Maintenance opérationnelle	Bonne	Faible	Très bonne	Les CSV sont vite chronophages.	Oui
Industrialisation long terme	Moyenne	Faible	Très bonne	L'ETL devient pertinent si le périmètre grandit.	Non, à ce stade

5. Cohérence des solutions avec le besoin

5.1 Explication détaillée de chaque solution proposée

La connexion directe à la base SQLite présente le meilleur équilibre entre simplicité, fiabilité et délai. Elle permet de repartir de la source unique consolidée mentionnée dans la note de cadrage, tout en conservant une chaîne de transformation courte et lisible. L'import dans Power Query sécurise les traitements sans imposer une infrastructure supplémentaire.

L'extraction CSV constitue une solution de contournement possible mais non optimale. Elle fragilise la gouvernance des données, multiplie les risques de versions divergentes et introduit des manipulations manuelles qui nuisent à la traçabilité du processus.

La mise en place d'un ETL dédié est une solution légitime dans une logique d'industrialisation à moyen terme, notamment si Bottleneck souhaite croiser demain plusieurs sources, historiser davantage ou alimenter plusieurs outils. En revanche, dans le cadre strict du projet, elle est surdimensionnée au regard du volume, du périmètre et du calendrier.

5.2 Alignement des solutions avec les besoins identifiés

Le besoin prioritaire de Bottleneck n'est plus de réparer la donnée mais de la rendre exploitable rapidement dans un tableau de bord métier. La solution retenue doit donc être suffisamment robuste pour garantir la qualité des analyses, tout en restant assez légère pour être déployée dans le temps du projet.

À cet égard, une architecture articulée autour de la base SQLite, de Power Query et de Power BI est pleinement alignée avec les attentes : elle s'appuie sur une base déjà fiabilisée, autorise les jointures et la normalisation nécessaires, et débouche directement sur le livrable demandé.

Les résultats de l'audit SQL renforcent ce choix : les clés sont uniques, les tables Sales et Promo s'alignent complètement sur Finance, et les SKU de Finance absents de Web n'ont aucun impact commercial. Le modèle cible peut donc être recentré sur le catalogue Web actif sans perte d'information utile pour le pilotage.

Préconisation retenue. Utiliser la base SQLite comme source unique d'extraction, importer les tables dans Power BI via Power Query, construire une table de faits consolidée centrée sur Finance, filtrée sur les SKU présents dans Web, puis compléter le modèle par une dimension produit et une dimension calendrier.

5.3 Avantages et limites de chaque approche

Approche	Avantages	Limites
Connexion directe SQLite + Power Query	Chaîne courte, source unique, très bonne traçabilité, temps de mise en œuvre compatible avec le projet, maintenance raisonnable.	Dépendance au fichier source ; gouvernance à renforcer si plusieurs utilisateurs doivent rafraîchir le modèle.
Extraction CSV	Simplicité apparente ; utile en secours ou pour contrôles ponctuels.	Risque élevé de fichiers divergents, opérations manuelles, maintenance faible, peu adaptée à un pilotage durable.
ETL dédié	Très bonne industrialisation, réutilisabilité, potentiel multi-sources à moyen terme.	Coût de mise en place plus élevé, complexité supérieure, disproportionné pour le périmètre actuel.

6. Conclusion

6.1 Synthèse des principales conclusions de l'analyse

L'analyse des solutions d'utilisation de la base de données Bottleneck conduit à retenir une option claire : l'entreprise dispose déjà d'une source unique suffisamment fiable pour être exploitée directement dans Power BI, à condition d'y appliquer une couche de préparation maîtrisée dans Power Query.

Les contrôles effectués sur la structure des tables confirment que le modèle peut être consolidé autour de Finance, avec enrichissement par Sales et Promo, puis raccordement au référentiel produit Web. Les problèmes identifiés relèvent moins de la qualité des données que de leur mise en forme analytique et de la nécessité de filtrer le périmètre réellement utile au pilotage.

Dans ces conditions, l'extraction CSV doit être écartée comme solution principale, et l'ETL dédié réservé à une trajectoire d'industrialisation ultérieure.

6.2 Recommandations pour la mise en œuvre des solutions proposées

- retenir Power BI comme outil unique de modélisation et de restitution, conformément au livrable attendu ;
- importer la base SQLite dans Power Query et y centraliser les transformations documentées ;
- construire une table de faits consolidée « produit × mois » issue de Finance, enrichie par Sales et Promo ;
- utiliser Web comme dimension produit après sélection des colonnes métier et exclusion des champs WordPress inutiles ;
- créer une dimension calendrier standardisée afin de fiabiliser les analyses temporelles ;

- écarter du périmètre analytique principal les 110 SKU présents uniquement dans Finance, puisqu'ils n'ont ni ventes ni promotions ;
- documenter les définitions de KPI (marge, prix HT, rotation des stocks, performance promotionnelle) afin d'assurer une lecture homogène entre direction, responsable des ventes et chefs de produits ;
- prévoir à moyen terme une montée en puissance vers un ETL ou un data mart si le nombre de sources, d'utilisateurs ou de cas d'usage devait croître.

6.3 Description détaillée des outils recommandés

Outil	Usage recommandé
DBeaver	Audit SQL, contrôle d'unicité, validation des jointures et lecture du schéma source.
SQLite / connecteur ODBC	Accès à la base source consolidée.
Power Query	Préparation des données, normalisation des clés, fusion des tables, filtrage du périmètre utile.
Power BI	Modélisation, mesures DAX, visualisations, filtres et storytelling de restitution.

6.4 Exemples de visualisations de données proposées

- Page de garde : KPI cards (CA, marge, taux de marge, stock, part promo), alertes et tendances mensuelles.
- Page marge & inflation : évolution du prix d'achat, évolution du prix de vente, compression de marge, focus février.
- Page ventes & stocks : ventes hors promo, commandes fournisseurs, rotation des stocks, surstocks et ruptures potentielles.
- Page portefeuille produits : tops/flops produits, performance par segment, analyse du nouveau marché sans alcool.
- Page promotions : volume promo, prix promo, contribution au chiffre d'affaires, lecture de la rentabilité promotionnelle.